


Diagrama da Arquitetura de Dados

Diagrama Feito no miro:



https://miro.com/welcomeonboard/dkova28rS2FnazJoK0hwK1BvVnF3UWNZVTN3RGFQaW1KUHJ0VXIPNIU3UHMycG0xYzIYSjRxeXluSE56enJPSzVLUEUyckRqMHo0NXppcGw5SkxzVGhySWcyZjVjZlpKREMrRHJKaEhRaWxEY21NR0FxbIVBZG4wN3M4U2N4a1FQdGo1ZEV3bUdPQWRZUHQzSGI6V2NBPT0hdjE=?share_link_id=925417688732

Fluxo dos Dados

Dataset Olist (CSV)

Apache Airflow inicia o pipeline

Dados armazenados na Landing Zone


PySpark processa e grava na Bronze

Limpeza e validação na Silver

Agregações e métricas na Gold

Metabase consome a Gold para dashboards

Diagrama feito com IA:



O projeto adota a Arquitetura Medalhão (Medallion Architecture), organizada em quatro camadas principais: Landing, Bronze, Silver e Gold.

O fluxo inicia com a ingestão dos arquivos CSV do dataset Olist. O processo é orquestrado pelo Apache Airflow, responsável pela execução e monitoramento das etapas do pipeline.

Os dados são inicialmente armazenados na Landing Zone em formato CSV, preservando a estrutura original dos arquivos.

Em seguida, utilizando Apache Spark (PySpark), os dados são convertidos para o formato Delta Lake e armazenados na camada Bronze, mantendo os registros brutos para fins de rastreabilidade.

Na camada Silver são realizadas atividades de limpeza, validação, padronização e integração dos dados, garantindo sua qualidade para consumo posterior.

A camada Gold contém os dados refinados e agregados de acordo com as necessidades analíticas do negócio, servindo como fonte para relatórios e dashboards.

Por fim, o consumo dos dados ocorre através do Metabase, que se conecta à camada Gold para geração de indicadores e visualizações analíticas.

Componente	Tecnologia
Orquestração	Apache Airflow
Processamento	Apache Spark (PySpark)
Armazenamento Bronze	Delta Lake
Armazenamento Silver	Delta Lake
Armazenamento Gold	Delta Lake
Visualização	Metabase
Origem dos Dados	Dataset Olist (CSV)
Ambiente	Docker Compose