

1. Objetivo

Este documento tem por finalidade registrar tecnicamente as tabelas do dataset público da Olist que serão utilizadas no modelo transacional do projeto de Engenharia de Software. A documentação abrange:

- Nome e finalidade de cada tabela;
- Colunas existentes nos arquivos CSV de origem;
- Tipo de dado sugerido para modelagem SQL;
- Indicação de aceite ou rejeição de valores nulos;
- Quantidade de valores nulos observada na versão pública do dataset;
- Identificação de chaves primárias (PK), estrangeiras (FK) e candidatas (CK);
- Relacionamentos para elaboração do Diagrama Entidade-Relacionamento (DER).

2. Fonte dos Dados

O dataset público da Olist contém dados de aproximadamente 100 mil pedidos realizados entre 2016 e 2018, permitindo análise por status do pedido, preço, pagamento, frete, localização do cliente, atributos dos produtos e avaliações dos clientes.

2.1 Arquivos Considerados

Arquivo CSV	Tabela no Modelo	Linhas (versão pública)
olist_customers_dataset.csv	customers	99.441
olist_geolocation_dataset.csv	geolocation	1.000.163
olist_orders_dataset.csv	orders	99.441
olist_order_items_dataset.csv	order_items	112.650
olist_order_payments_dataset.csv	order_payments	103.886
olist_order_reviews_dataset.csv	order_reviews	99.224
olist_products_dataset.csv	products	32.951
olist_sellers_dataset.csv	sellers	3.095
product_category_name_translation.csv	product_category_name_translation	71
Derivada de orders	entregas	99.441 (caso materializada 1:1 com orders)

Observação: A tabela entregas não é um arquivo CSV original do dataset público da Olist. Ela foi documentada como tabela derivada a partir dos campos de entrega existentes em orders, pois foi citada no escopo do card.

3. Convenções Adotadas

Termo	Significado
PK	Chave primária
FK	Chave estrangeira
CK	Chave candidata
VARCHAR	Campo textual curto ou identificador
CHAR(2)	Sigla de estado brasileiro, ex.: SP, RJ, MG
TEXT	Texto livre, geralmente comentário ou mensagem
INT	Número inteiro
DECIMAL(10,2)	Número decimal – valores monetários
DECIMAL(10,7)	Número decimal – latitude/longitude
TIMESTAMP	Data e hora
BOOLEAN	Verdadeiro/falso
SIM em "Aceita nulo?"	A coluna pode conter valores ausentes no dataset
NÃO em "Aceita nulo?"	A coluna não possui valores ausentes na versão pública analisada

Observação: Os arquivos CSV não possuem constraints físicas. As chaves indicadas neste documento são propostas para modelagem relacional e devem ser aplicadas no banco de dados durante a criação do modelo físico.

4. Resumo dos Relacionamentos

Origem	Coluna	Destino	Coluna	Cardinalidade	Observação
customers	customer_id	orders	customer_id	1:1	customer_id identifica o cliente no contexto de um pedido. Na base pública da Olist, a relação entre customers.customer_id e orders.customer_id ocorre como 1:1. Para analisar clientes com mais de um pedido, utilizar customer_unique_id.
orders	order_id	order_items	order_id	1:0..N	Um pedido pode possuir vários itens.
orders	order_id	order_payments	order_id	1:0..N	Um pedido pode ter mais de uma sequência de pagamento.

Origem	Coluna	Destino	Coluna	Cardinalidade	Observação
orders	order_id	order_reviews	order_id	1:0..N	A avaliação é vinculada ao pedido; validar duplicidades no modelo físico.
products	product_id	order_items	product_id	1:N	Um produto pode aparecer em vários itens de pedido.
sellers	seller_id	order_items	seller_id	1:N	Um vendedor pode vender vários itens.
product_category_name_translation	product_category_name	products	product_category_name	1:N	Uma categoria pode estar em vários produtos.
geolocation	geolocation_zip_code_prefix	customers	customer_zip_code_prefix	N:N lógica	geolocation contém múltiplas linhas por prefixo de CEP. Não é FK rígida sem tratamento.
geolocation	geolocation_zip_code_prefix	sellers	seller_zip_code_prefix	N:N lógica	Relação por prefixo de CEP, sujeita a duplicidade.
orders	order_id	entregas	order_id	1:1	Apenas se entregas for materializada como tabela derivada.

5. Dicionário de Dados por Tabela

5.1 Tabela customers

Arquivo: olist_customers_dataset.csv | PK: customer_id

Armazena os clientes dos pedidos e sua localização básica. O campo customer_unique_id identifica o consumidor de forma única no negócio, enquanto customer_id identifica o cliente dentro de um pedido específico.

Coluna	Tipo SQL	Aceita Nulo?	Nulos	Chave	Descrição
customer_id	VARCHAR(32)	NÃO	0	PK	Identificador do cliente no contexto do pedido.
customer_unique_id	VARCHAR(32)	NÃO	0		Identificador único do consumidor. Pode se repetir em diferentes pedidos.

Coluna	Tipo SQL	Aceita Nulo?	Nulos	Chave	Descrição
customer_zip_code_prefix	INT	NÃO	0	FK lógica	Prefixo do CEP do cliente. Relacionável a geolocation.geolocation_zip_code_prefix.
customer_city	VARCHAR(100)	NÃO	0		Cidade do cliente.
customer_state	CHAR(2)	NÃO	0		Estado do cliente (sigla de 2 letras).

Relacionamentos

- customers.customer_id → orders.customer_id
- customers.customer_zip_code_prefix → geolocation.geolocation_zip_code_prefix (relacionamento lógico por CEP)

5.2 Tabela geolocation

Arquivo: olist_geolocation_dataset.csv | PK: chave surrogate (recomendado)

Armazena coordenadas geográficas associadas a prefixos de CEP brasileiros. O mesmo geolocation_zip_code_prefix pode aparecer várias vezes com latitudes, longitudes e cidades distintas. Para o modelo físico, recomenda-se criar uma tabela agregada por CEP ou usar uma chave surrogate.

Coluna	Tipo SQL	Aceita Nulo?	Nulos	Chave	Descrição
geolocation_zip_code_prefix	INT	NÃO	0		Prefixo do CEP. Não é único no arquivo original.
geolocation_lat	DECIMAL(10,7)	NÃO	0		Latitude associada ao prefixo de CEP.
geolocation_lng	DECIMAL(10,7)	NÃO	0		Longitude associada ao prefixo de CEP.
geolocation_city	VARCHAR(100)	NÃO	0		Cidade associada ao prefixo de CEP.
geolocation_state	CHAR(2)	NÃO	0		Estado associado ao prefixo de CEP.

Relacionamentos

- geolocation.geolocation_zip_code_prefix → customers.customer_zip_code_prefix
- geolocation.geolocation_zip_code_prefix → sellers.seller_zip_code_prefix

Observação: Não usar `geolocation_zip_code_prefix` como PK diretamente sem verificar duplicidade. Em um modelo relacional mais limpo, criar uma dimensão `geolocation_prefix` com um único registro por prefixo de CEP.

5.3 Tabela orders

Arquivo: `olist_orders_dataset.csv` | PK: `order_id`

Armazena os pedidos realizados, incluindo cliente associado, status e as principais datas do ciclo do pedido (compra, aprovação, envio à transportadora, entrega ao cliente e estimativa de entrega).

Coluna	Tipo SQL	Aceita Nulo?	Nulos	Chave	Descrição
<code>order_id</code>	<code>VARCHAR(32)</code>	NÃO	0	PK	Identificador único do pedido.
<code>customer_id</code>	<code>VARCHAR(32)</code>	NÃO	0	FK	Cliente associado ao pedido. Referência <code>customers.customer_id</code> .
<code>order_status</code>	<code>VARCHAR(20)</code>	NÃO	0		Status do pedido: delivered, shipped, canceled, invoiced, entre outros.
<code>order_purchase_timestamp</code>	<code>TIMESTAMP</code>	NÃO	0		Data e hora em que a compra foi realizada.
<code>order_approved_at</code>	<code>TIMESTAMP</code>	SIM	160		Data e hora de aprovação. Nula em pedidos não aprovados ou cancelados.
<code>order_delivered_carrier_date</code>	<code>TIMESTAMP</code>	SIM	1.783		Data e hora de entrega do pedido à transportadora.
<code>order_delivered_customer_date</code>	<code>TIMESTAMP</code>	SIM	2.965		Data e hora de entrega do pedido ao cliente.
<code>order_estimated_delivery_date</code>	<code>TIMESTAMP</code>	NÃO	0		Data estimada de entrega ao cliente.

Relacionamentos

- orders.customer_id → customers.customer_id
- orders.order_id → order_items.order_id
- orders.order_id → order_payments.order_id
- orders.order_id → order_reviews.order_id
- orders.order_id → entregas.order_id (caso a tabela entregas seja criada)

5.4 Tabela order_items

Arquivo: olist_order_items_dataset.csv | PK: order_id + order_item_id (composta)

Detalha os itens e produtos vendidos em cada pedido, incluindo vendedor responsável, preço, valor de frete e data limite de envio. A chave primária é composta pelos campos order_id e order_item_id.

Coluna	Tipo SQL	Aceita Nulo?	Nulos	Chave	Descrição
order_id	VARCHAR(32)	NÃO	0	PK/FK	Pedido associado ao item. Referencia orders.order_id.
order_item_id	INT	NÃO	0	PK	Sequência do item dentro do pedido (forma parte da PK composta).
product_id	VARCHAR(32)	NÃO	0	FK	Produto vendido. Referencia products.product_id.
seller_id	VARCHAR(32)	NÃO	0	FK	Vendedor responsável pelo item. Referencia sellers.seller_id.
shipping_limit_date	TIMESTAMP	NÃO	0		Data limite para envio do item pelo vendedor.
price	DECIMAL(10,2)	NÃO	0		Preço unitário do item.
freight_value	DECIMAL(10,2)	NÃO	0		Valor do frete associado ao item.

Relacionamentos

- order_items.order_id → orders.order_id
- order_items.product_id → products.product_id
- order_items.seller_id → sellers.seller_id

5.5 Tabela order_payments

Arquivo: olist_order_payments_dataset.csv | PK: order_id + payment_sequential (composta)

Armazena as formas e valores de pagamento dos pedidos. Um mesmo pedido pode ter mais de uma linha, por exemplo quando há uso combinado de voucher e cartão de crédito.

Coluna	Tipo SQL	Aceita Nulo?	Nulos	Chave	Descrição
order_id	VARCHAR(32)	NÃO	0	PK/FK	Pedido relacionado ao pagamento. Referencia orders.order_id.
payment_sequential	INT	NÃO	0	PK	Sequência do pagamento dentro do pedido (forma parte da PK composta).
payment_type	VARCHAR(30)	NÃO	0		Tipo de pagamento: credit_card, boleto, voucher, debit_card ou not_defined.
payment_installments	INT	NÃO	0		Número de parcelas do pagamento.
payment_value	DECIMAL(10,2)	NÃO	0		Valor pago nessa sequência de pagamento.

Relacionamentos

- order_payments.order_id → orders.order_id
-

5.6 Tabela order_reviews

Arquivo: olist_order_reviews_dataset.csv | **PK:** não definida no CSV, recomenda-se chave surrogate

Armazena as avaliações dos clientes sobre seus pedidos. Os campos de título e mensagem do comentário são opcionais, apresentando alto índice de nulos na base pública.

Coluna	Tipo SQL	Aceita Nulo?	Nulos	Chave	Descrição
review_id	VARCHAR (32)	NÃO	0		Identificador da avaliação. Pode apresentar duplicidade em alguns cenários do dataset.
order_id	VARCHAR (32)	NÃO	0	FK	Pedido avaliado. Referencia orders.order_id.
review_score	INT	NÃO	0		Nota da avaliação (1 a 5).
review_comment_title	TEXT	SIM	87.656		Título do comentário. Muitas avaliações não possuem título.
review_comment_message	TEXT	SIM	58.247		Mensagem textual da avaliação. Muitas avaliações não possuem comentário.
review_creation_date	TIMESTAMP	NÃO	0		Data de criação da avaliação.
review_answer_timestamp	TIMESTAMP	NÃO	0		Data e hora em que a avaliação foi respondida/processada.

Relacionamentos

- order_reviews.order_id → orders.order_id

Observação: O CSV original não impõe PK. Antes de criar a constraint física, validar se review_id é único na base usada pelo projeto. Em caso de duplicidade, criar uma chave surrogate review_sk ou usar composição técnica (review_id + order_id + sequencial).

5.7 Tabela products

Arquivo: olist_products_dataset.csv | PK: product_id

Armazena os produtos vendidos, suas categorias e atributos físicos e cadastrais. Vários campos admitem nulos, pois há produtos sem categoria ou dimensões cadastradas na base pública.

Coluna	Tipo SQL	Aceita Nulo?	Nulos	Chave	Descrição
product_id	VARCHAR(32)	NÃO	0	PK	Identificador único do produto.
product_category_name	VARCHAR(100)	SIM	610	FK lógica	Categoria do produto em português. Referencia product_category_name_translation.
product_name_lenght	INT	SIM	610		Tamanho do nome do produto. Coluna com erro ortográfico no dataset original (lenght).
product_description_lenght	INT	SIM	610		Tamanho da descrição do produto. Coluna com erro ortográfico no dataset original.
product_photos_qty	INT	SIM	610		Quantidade de fotos cadastradas para o produto.
product_weight_g	INT	SIM	2		Peso do produto em gramas.
product_length_cm	INT	SIM	2		Comprimento do produto em centímetros.
product_height_cm	INT	SIM	2		Altura do produto em centímetros.
product_width_cm	INT	SIM	2		Largura do produto em centímetros.

Relacionamentos

- products.product_id → order_items.product_id
- products.product_category_name → product_category_name_translation.product_category_name

Observação: Os campos `product_name_lenght` e `product_description_lenght` estão grafados com erro ortográfico (`lenght`) no dataset original. Recomenda-se manter o nome original na camada `raw/staging` e corrigir apenas em camada tratada, se houver padronização. A relação entre `products.product_category_name` e `product_category_name_translation.product_category_name` deve ser tratada como lógica/opcional na base bruta, pois há produtos sem categoria e há mais categorias distintas em `products` do que registros na tabela de tradução. Antes de criar uma FK física, é necessário tratar categorias ausentes ou sem tradução.

5.8 Tabela sellers

Arquivo: `olist_sellers_dataset.csv` | PK: `seller_id`

Armazena dados dos vendedores que realizam vendas no marketplace Olist, incluindo localização geográfica por prefixo de CEP.

Coluna	Tipo SQL	Aceita Nulo?	Nulos	Chave	Descrição
<code>seller_id</code>	<code>VARCHAR (32)</code>	NÃO	0	PK	Identificador único do vendedor.
<code>seller_zip_code_prefix</code>	<code>INT</code>	NÃO	0	FK lógica	Prefixo do CEP do vendedor. Relacionável a <code>geolocation.geolocation_zip_code_prefix</code> .
<code>seller_city</code>	<code>VARCHAR (100)</code>	NÃO	0		Cidade do vendedor.
<code>seller_state</code>	<code>CHAR (2)</code>	NÃO	0		Estado do vendedor (sigla de 2 letras).

Relacionamentos

- `sellers.seller_id` → `order_items.seller_id`
- `sellers.seller_zip_code_prefix` → `geolocation.geolocation_zip_code_prefix` (relacionamento lógico por CEP)

5.9 Tabela product_category_name_translation

Arquivo: `product_category_name_translation.csv` | PK: `product_category_name`

Tabela de tradução que mapeia os nomes das categorias de produtos do português para o inglês. Contém 71 categorias distintas na versão pública.

Coluna	Tipo SQL	Aceita Nulo?	Nulos	Chave	Descrição
<code>product_category_name</code>	<code>VARCHAR (100)</code>	NÃO	0	PK	Nome da categoria do produto em português.
<code>product_category_name_english</code>	<code>VARCHAR (100)</code>	NÃO	0		Nome da categoria do produto em inglês.

Relacionamentos

- product_category_name_translation.product_category_name → products.product_category_name

5.10 Tabela entregas (derivada)

Arquivo: Derivada de orders (não há CSV original) | PK: order_id

Tabela derivada criada a partir dos campos de entrega existentes em orders. Seu objetivo é isolar as informações de entrega, facilitando análises de prazo, atraso e performance logística. Deve ser criada somente se o projeto decidir separar essas informações da tabela orders.

Coluna	Tipo SQL	Aceita Nulo ?	Nulos	Chave	Regra / Cálculo	Descrição
order_id	VARCHAR (32)	NÃO	0	PK/FK	orders.order_id	Pedido associado à entrega.
order_delivered_carrier_date	TIMESTAMP	SIM	1783		orders.order_delivered_carrier_date	Data de entrega do pedido à transportadora.
order_delivered_customer_date	TIMESTAMP	SIM	2965		orders.order_delivered_customer_date	Data de entrega do pedido ao cliente.
order_estimated_delivery_date	TIMESTAMP	NÃO	0		orders.order_estimated_delivery_date	Data estimada de entrega.
atraso_dias	INT	SIM	2965		DATE(order_delivered_customer_date) - DATE(order_estimated_delivery_date)	Dias de atraso. Valor negativo = entrega antecipada.
entrega_no_prazo	BOOLEAN	SIM	2965		order_delivered_customer_date <= order_estimated_delivery_date	Indica se a entrega ocorreu dentro do prazo estimado.

Relacionamentos

- entregas.order_id → orders.order_id

Observação: Quando order_delivered_customer_date for nulo, os campos atraso_dias e entrega_no_prazo também devem ser nulos. Pedidos cancelados, indisponíveis ou ainda não entregues podem não possuir datas completas de entrega.

6. Recomendações para o Modelo Físico

6.1 Chaves Primárias Sugeridas

Tabela	Chave Primária Sugerida
customers	customer_id
orders	order_id
order_items	order_id, order_item_id (composta)
order_payments	order_id, payment_sequential (composta)
products	product_id
sellers	seller_id
product_category_name_translation	product_category_name
entregas	order_id
geolocation	Criar chave surrogate ou tratar agregação por CEP
order_reviews	Validar unicidade; se necessário, criar chave surrogate

6.2 Pontos que Exigem Validação Antes das Constraints

Ponto	Motivo
geolocation_zip_code_prefix	Não é único no arquivo original.
review_id em order_reviews	Pode não ser chave única confiável dependendo da versão/limpeza aplicada.
Relação por CEP (customers e sellers)	O relacionamento com geolocation é lógico; não é uma FK forte sem deduplicação prévia.
Campos de data em orders	Algumas datas são nulas quando o pedido não concluiu determinadas etapas do ciclo.
Campos de produto	Há produtos com categoria, tamanho de nome, descrição, fotos e dimensões ausentes.